

Прогнозирование кол-ва преступлений в Чикаго

Юнисов Ренат, Хайретинов Григорий

Про проект и датасет

Предсказывать ежедневное кол-во преступлений в Чикаго

Тип задачи

Данные

ЦЕЛЬ

Регрессия

Криминал в Чикаго

Исключить выбросы

Временной ряд

Временные метки

Отобрать признаки




Табличные данные

Реальные выбросы



Интерпретировать
модель

Данные

- В среднем - ежегодное количество преступлений до 2020 года - 270 тыс.
- Во время пандемии - снижение на 18%.
- Летний сезон и 12 часов - пик преступности




Про выбросы




Про отбор признаков

Фильтры



Встроенные



Голосование



Выбор модели и подбор параметров


Model / Metrics	MAE	R2
Random Forest (Baseline)	118.02	-1.42
После feature engineering LGBM	62.96	0.198
Optuna + LGBM	55.33	0.37
Optuna + Ridge	55.37	0.39

```
# LGBM
params = {
    "n_estimators": trial.suggest_int("n_estimators", 100, 600),
    "learning_rate": trial.suggest_float("learning_rate", 0.01, 0.08, log=True),
    "num_leaves": trial.suggest_int("num_leaves", 8, 35),
    "max_depth": trial.suggest_int("max_depth", 2, 5),
    "min_child_samples": trial.suggest_int("min_child_samples", 30, 200),
    "subsample": trial.suggest_float("subsample", 0.7, 1.0),
    "colsample_bytree": trial.suggest_float("colsample_bytree", 0.7, 1.0),
    "reg_alpha": trial.suggest_float("reg_alpha", 0.1, 20.0, log=True),
    "reg_lambda": trial.suggest_float("reg_lambda", 0.1, 50.0, log=True),
    "random_state": 42,
    "verbose": -1,
}


# Ridge
alpha = trial.suggest_float("alpha", 1e-2, 1e5, log=True)
```

SHAP

LGBM

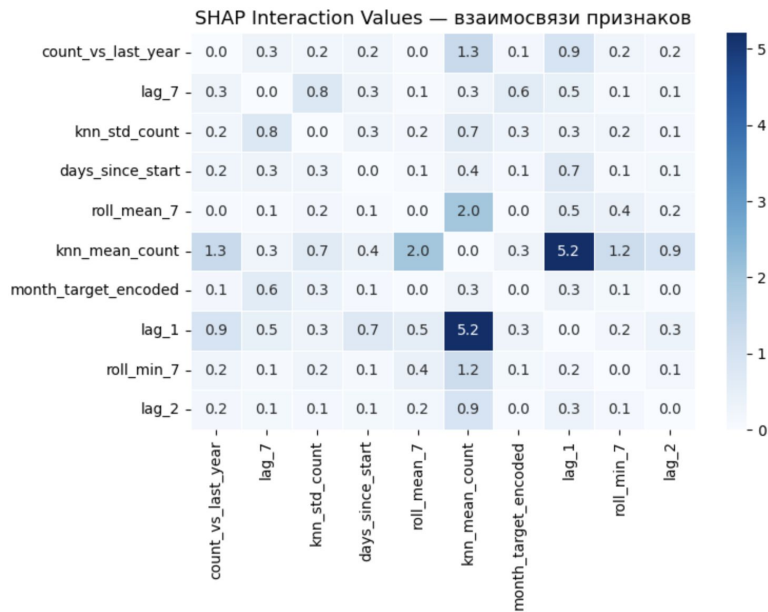


Ridge




Интерпертация Ridge

SHAP Flow

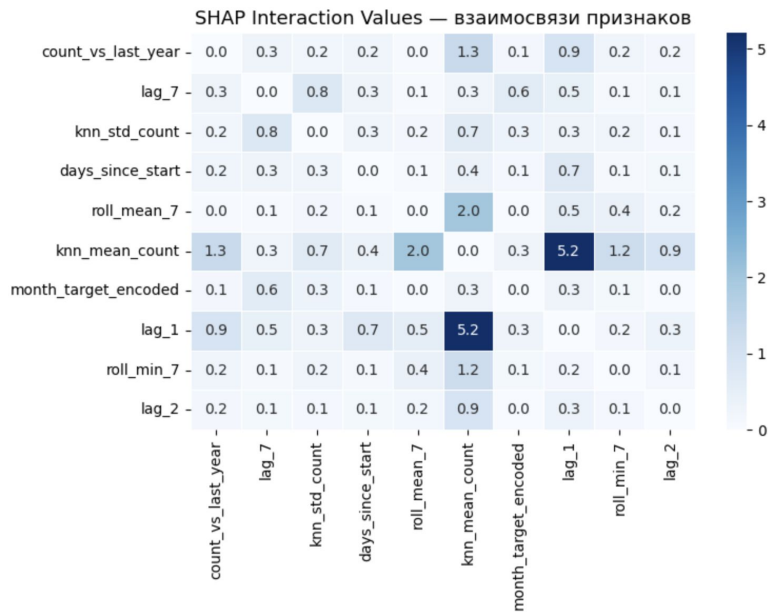


Feature importance




Интерпертация Ridge

SHAP Flow



Feature importance



Результаты по метрикам и выводы



Model	MAE	R ²
Ridge + SHAP-кластер	47.182	0.523
SHAP-эмбединги + признаки	49.783	NaN
SHAP-эмбединги (только)	50.910	NaN
Ridge + Optuna	55.357	0.387
LightGBM + SHAP-кластер	55.777	0.357
LightGBM + Optuna	59.084	0.301